Comparación entre embeddings de turno y estados latentes dinámicos para la recuperación aproximada de vecinos en diálogos orientados a tareas

Curso: Algoritmos Recientes para Búsqueda de Proximidad en Altas Dimensiones

Doctorando: Mg. Juan Manuel Fernández

Resumen:

En los sistemas de diálogo orientados a tareas, la representación del estado conversacional constituye un componente central para la toma de decisiones del agente. En enfoques actuales, cada turno del diálogo se representa mediante embeddings semánticos individuales. Sin embargo, los diálogos son procesos secuenciales en los que el significado de cada intervención depende del historial de la conversación, lo que motiva el estudio de representaciones que integren información acumulativa del diálogo mediante estados latentes dinámicos. Estas representaciones pueden utilizarse como consultas en sistemas de recuperación vectorial, donde métodos de búsqueda aproximada de vecinos permiten identificar estados o fragmentos de diálogo similares en grandes colecciones de interacciones.

En este trabajo se comparan embeddings estáticos de turno con estados latentes dinámicos construidos a lo largo del diálogo. Utilizando el corpus MultiWOZ 2.2, se generaron embeddings mediante dos modelos basados en los sentence transformers (all-mpnet-base-v2 y all-MiniLM-L6-v2) y se evaluó su comportamiento en distintos índices de búsqueda aproximada implementados con FAISS. Los resultados permiten explorar el potencial de los estados latentes dinámicos como consultas informativas para recuperar estados conversacionales similares y facilitar la reutilización de estrategias de acción en agentes orientados a tareas.

Introducción

Los sistemas de diálogo orientados a tareas constituyen un área central dentro de la investigación en procesamiento del lenguaje natural y agentes conversacionales. En este tipo de sistemas, el agente interactúa con el usuario con el objetivo de completar una tarea

específica, como reservar un restaurante, buscar información sobre hoteles o solicitar un servicio de transporte. Para ello, el sistema debe interpretar cada intervención del usuario, mantener una representación coherente del estado del diálogo y decidir la acción más adecuada en cada turno de la interacción (Young et al., 2013; Chen et al., 2017).

Una práctica extendida para representar las intervenciones del diálogo consiste en utilizar embeddings semánticos, es decir, representaciones vectoriales densas generadas a partir de modelos de lenguaje. En este enfoque, cada turno del diálogo se codifica de manera independiente mediante un vector que captura información semántica del enunciado. Este tipo de representaciones permite aplicar técnicas de recuperación vectorial, clasificación o clustering sobre grandes colecciones de interacciones conversacionales (Devlin et al., 2019; Reimers & Gurevych, 2019).

Sin embargo, los diálogos son procesos intrínsecamente secuenciales en los que el significado de cada intervención depende del contexto acumulado de la conversación. Representar cada turno de forma aislada puede resultar insuficiente para capturar la evolución del estado conversacional, especialmente en diálogos largos o en interacciones donde la información relevante se distribuye a lo largo de múltiples turnos. Por esta razón, resulta de interés explorar representaciones que integren progresivamente la información del diálogo y permitan modelar estados latentes que evolucionan a medida que avanza la interacción.

Las representaciones vectoriales del estado del diálogo también pueden utilizarse como consultas en sistemas de recuperación vectorial, donde el objetivo consiste en encontrar elementos similares dentro de grandes colecciones de vectores. En este contexto, los métodos de búsqueda aproximada de vecinos más cercanos permiten escalar la recuperación a conjuntos de datos de gran tamaño, manteniendo tiempos de consulta reducidos incluso cuando el número de vectores indexados es elevado (Johnson et al., 2017; Malkov & Yashunin, 2018).

En este contexto, el presente trabajo analiza el uso de representaciones vectoriales en diálogos orientados a tareas, comparando embeddings estáticos de turno con estados latentes dinámicos que acumulan información a lo largo de la conversación. A partir del corpus MultiWOZ 2.2 (Budzianowski et al., 2018) se generan representaciones vectoriales de los turnos del diálogo y se construyen estados dinámicos que integran progresivamente el contexto conversacional. Sobre estas representaciones se evalúa el comportamiento de distintos métodos de búsqueda aproximada de vecinos implementados mediante la librería FAISS, con el objetivo de analizar cómo el tipo de representación afecta la recuperación de

estados similares y explorar el potencial de los estados dinámicos como consultas informativas en sistemas de recuperación vectorial para agentes conversacionales orientados a tareas.

Trabajos relacionados

Los métodos de búsqueda aproximada de vecinos más cercanos (ANN) se han convertido en una herramienta fundamental para realizar recuperación de vectores en espacios de alta dimensionalidad. A diferencia de los métodos de búsqueda exacta, los enfoques ANN permiten reducir significativamente el tiempo de consulta mediante estructuras de indexación especializadas, manteniendo una alta probabilidad de recuperar vecinos relevantes. Entre los algoritmos más utilizados se encuentran los métodos basados en grafos navegables y técnicas de cuantización del espacio vectorial.

Uno de los enfoques más difundidos es Hierarchical Navigable Small World (HNSW) (Malkov y Yashunin, 2018), que construye una estructura jerárquica de grafos donde los nodos representan vectores y las conexiones permiten navegar eficientemente hacia regiones del espacio vectorial cercanas al vector de consulta. Otra línea de trabajo utiliza Product Quantization (PQ) para comprimir vectores y acelerar la búsqueda mediante aproximaciones del espacio de distancias (Jégou et al., 2011), estrategia ampliamente utilizada en sistemas de recuperación vectorial de gran escala (Johnson et al., 2017).

En el contexto de procesamiento del lenguaje natural, las representaciones vectoriales generadas por modelos de lenguaje han permitido aplicar estos métodos de recuperación a tareas como búsqueda semántica, recuperación de información y sistemas conversacionales. Sin embargo, la mayoría de los enfoques utilizan representaciones estáticas de las unidades textuales, como oraciones o turnos de diálogo codificados de forma independiente.

El presente trabajo se diferencia de estos enfoques al explorar el uso de estados latentes dinámicos de diálogo como consultas en sistemas de recuperación vectorial. En lugar de utilizar únicamente embeddings individuales de turno, se construyen representaciones que integran información acumulativa del diálogo, permitiendo analizar cómo esta forma de representación afecta el comportamiento de los métodos ANN en la recuperación de estados conversacionales similares.

Metodología

Los experimentos se diseñaron con el objetivo de comparar el comportamiento de representaciones estáticas de turno y estados latentes dinámicos en tareas de recuperación vectorial dentro de diálogos orientados a tareas. Para ello se construyó un pipeline experimental que incluye la preparación del corpus, la generación de embeddings de turno, la construcción de estados dinámicos de diálogo y la evaluación mediante métodos de búsqueda aproximada de vecinos.

Como fuente de datos se utilizó el corpus MultiWOZ 2.2 (Budzianowski et al., 2018), uno de los conjuntos de datos más utilizados en investigación sobre sistemas de diálogo orientados a tareas. Este corpus contiene diálogos multi-turno en múltiples dominios, incluyendo reservas de restaurantes, hoteles, transporte y atracciones turísticas. A partir del dataset original se construyó una representación tabular en la que cada registro corresponde a un turno del diálogo, incluyendo información como el identificador del diálogo, el número de turno, el hablante y el contenido textual. Esta estructura permitió procesar cada intervención de manera independiente y reconstruir posteriormente la secuencia completa de cada conversación.

ID Turno	Usuario	Turno
0	USER	I would like to find a restaurant named Tandoori Palace. Do you know of that restaurant?
1	SYSTEM	I do. It's a very nice Indian restaurant on the West side.
2	USER	Can you give me the postcode for it please?
3	SYSTEM	The postcode is cb43le. May I help you with anything else?
4	USER	That will be all, thanks. Goodbye!

Tabla 1: Extracto del diálogo SNG0693.json del dataset MultiWOZ 2.2

Para representar cada turno del diálogo se generaron embeddings semánticos utilizando modelos de sentence transformers (Reimers y Gurevych, 2019). En particular se emplearon dos modelos preentrenados, all-mpnet-base-v2 y all-MiniLM-L6-v2, que producen representaciones vectoriales densas capaces de capturar similitud semántica entre fragmentos de texto. Para cada turno del diálogo se generó un embedding que posteriormente fue utilizado tanto para la indexación vectorial como para la construcción de estados dinámicos del diálogo.

Además de las representaciones estáticas de turno, se construyeron estados latentes dinámicos de diálogo que acumulan información a lo largo de la conversación. Para cada diálogo se generó una secuencia de estados donde cada nuevo estado se calcula a partir del estado anterior y del embedding del turno actual, seguido de un proceso de normalización del vector resultante. De esta manera se obtiene una representación que integra progresivamente el contexto conversacional, permitiendo modelar la evolución del estado del diálogo a medida que avanza la interacción. Como resultado de este proceso se obtuvieron dos tipos de representaciones vectoriales: embeddings estáticos de turno y estados latentes dinámicos de diálogo.

Para evaluar el comportamiento de estas representaciones se utilizaron métodos de búsqueda aproximada de vecinos más cercanos (ANN) implementados mediante la librería FAISS (Johnson et al., 2017). Se construyeron distintos índices vectoriales con el objetivo de analizar el desempeño de diferentes estrategias de recuperación. En particular se evaluaron cuatro tipos de índice: Flat, utilizado como referencia de búsqueda exacta; IVF (Inverted File Index), basado en partición del espacio vectorial; HNSW (Hierarchical Navigable Small World) (Malkov y Yashunin, 2018), basado en grafos navegables; y IVFPQ, que combina partición del espacio con técnicas de Product Quantization (Jégou et al., 2011).

Cada índice fue construido utilizando los embeddings generados a partir del corpus de diálogos. Posteriormente se realizaron consultas vectoriales utilizando tanto embeddings de turno como estados dinámicos con el objetivo de comparar el comportamiento de ambas representaciones en la recuperación de vecinos similares. La evaluación consideró métricas asociadas a la calidad de la recuperación y al rendimiento computacional de los distintos métodos de indexación. Adicionalmente se analizó la evolución de la similitud entre embeddings de turno y estados dinámicos a lo largo de los diálogos, con el fin de observar cómo cambia la representación del estado conversacional a medida que progresa la interacción.

La implementación de los experimentos se organizó en tres notebooks de trabajo:

- La notebook *notebook_01_carga_datos_y_embeddings.ipynb* se utilizó para la preparación del corpus y la generación de embeddings de turno a partir del dataset MultiWOZ 2.2.
- La notebook *notebook_02_indexacion_y_ann.ipynb* se empleó para la construcción de índices vectoriales y la evaluación de distintos métodos de búsqueda aproximada de vecinos utilizando la librería FAISS.

- Finalmente, la notebook *notebook_03_estados_latentes_dinamicos.ipynb* se destinó a la construcción de estados latentes dinámicos de diálogo y al análisis comparativo entre representaciones estáticas y dinámicas en las tareas de recuperación vectorial.

Resultados[1]

En primer lugar se evaluó el comportamiento de distintos métodos de búsqueda aproximada de vecinos utilizando embeddings estáticos de turno generados a partir de los modelos all-mpnet-base-v2 y all-MiniLM-L6-v2. Como referencia se incluyó también un índice FlatL2, que realiza búsqueda exacta y permite establecer una línea base para comparar el rendimiento de los métodos aproximados.

Los experimentos se realizaron utilizando cuatro tipos de índice implementados en la librería FAISS: FlatL2, IVF, HNSW e IVFPQ. Para cada configuración se midió el recall de recuperación y el tiempo promedio de consulta, permitiendo analizar el compromiso entre precisión y eficiencia computacional. La Tabla 1 presenta una comparación del rendimiento obtenido para ambos modelos de embeddings.

Índice	Recall@5 (MPNet)	Recall@5 (MiniLM)	Tiempo ms (MPNet)	Tiempo ms (MiniLM)
FlatL2	1.00	1.00	134.30	68.80
IVF	1.00	1.00	10.26	11.42
HNSW	**1.00**	**1.00**	**1.55**	**1.17**
IVFPQ	1.00	0.80	1.78	1.98

Tabla 2: Resultados de recuperación por técnica y modelo de embeddings

Como era esperable, el índice FlatL2 presenta los mayores tiempos de consulta al realizar búsqueda exacta sobre todo el conjunto de vectores. En contraste, los métodos de búsqueda aproximada reducen significativamente el tiempo de recuperación manteniendo

[1] El código y los datos necesarios para replicar los resultados se encuentran en el siguiente repositorio: https://github.com/jumafernandez/ANN-UNSL

niveles altos de recall. En particular, el índice HNSW presenta el mejor compromiso entre precisión y eficiencia computacional para ambos modelos de embeddings.

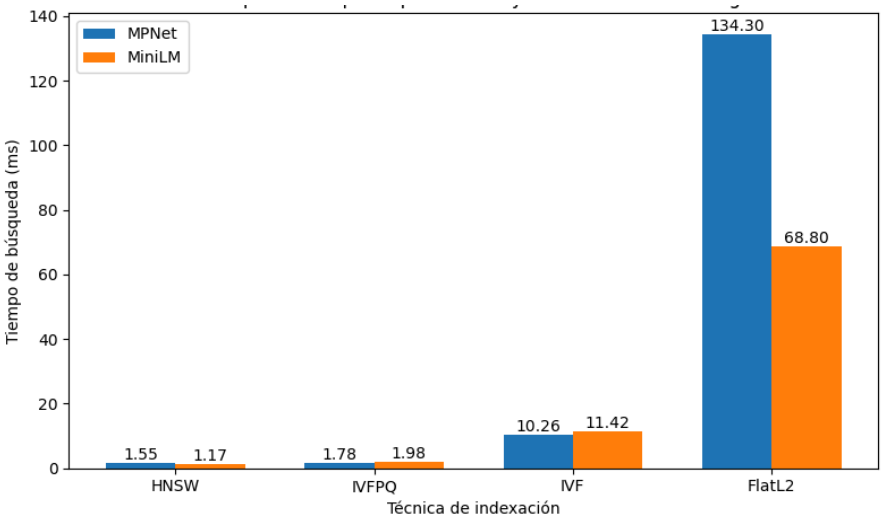

Figura 1: Tiempo de búsqueda por técnica y modelo de embedding

Específicamente, los resultados de la recuperación muestran que los índices FlatL2, IVF y HNSW alcanzan valores de recall@5 iguales a 1.00 para ambos modelos de embeddings. La única excepción se observa en IVFPQ utilizando MiniLM, donde el recall desciende a 0.80, mientras que con MPNet se mantiene en 1.00. En cuanto al tiempo de consulta, el menor valor se obtiene utilizando HNSW con embeddings MiniLM (1.17 ms). Para el resto de los índices evaluados, los embeddings generados con MPNet presentan tiempos de consulta ligeramente menores que los obtenidos con MiniLM. Estos resultados indican que ambos modelos producen representaciones comparables en términos de calidad de recuperación, mientras que las diferencias de rendimiento temporal dependen tanto del modelo de embeddings como del tipo de índice utilizado.

Tras analizar el comportamiento de los métodos de recuperación sobre embeddings de turno, se procedió a estudiar el efecto de utilizar representaciones semánticas dinámicas que incorporan el contexto acumulado del diálogo.

Para ello, se construyeron estados latentes dinámicos a partir de la secuencia de embeddings de cada conversación. Estos estados se obtienen mediante una actualización acumulativa que integra progresivamente la información semántica de los turnos previos. Formalmente, se calcula de manera recursiva como:

$$h_t = \text{LayerNorm}(h_{t-1} + e_t)$$

donde e_t representa el embedding del turno t,

h_t representa el estado dinámico en el turno t,

h_{t-1} representa el estado acumulado hasta el turno anterior,

LayerNorm(·) corresponde a una operación de normalización que estabiliza la magnitud del vector resultante.

De este modo, cada estado dinámico representa no solo el contenido del turno actual sino también el historial conversacional acumulado hasta ese punto.

Como primer análisis se evaluó la similitud coseno entre el embedding estático de cada turno y el estado dinámico correspondiente dentro de cada diálogo. Esta comparación permite observar cómo evoluciona la representación semántica a medida que el diálogo avanza e incorpora contexto adicional.

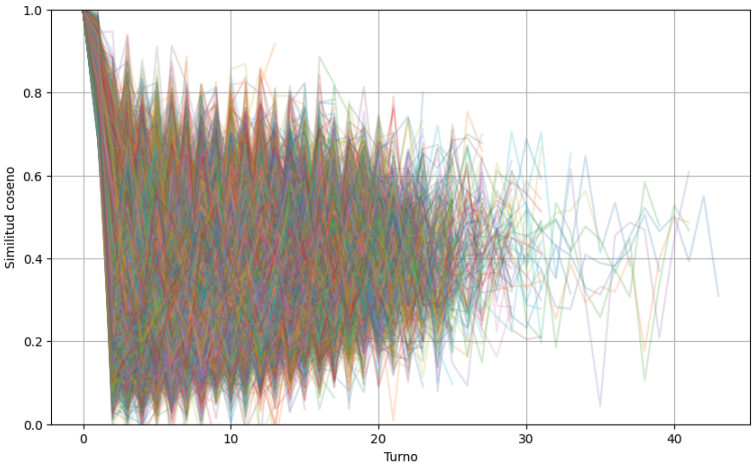

Figura 2: Evolución de la similitud entre los turnos y las representación semántica latente en el tiempo

La Figura 2 muestra la evolución de esta similitud para todas las conversaciones del corpus. Cada línea representa un diálogo individual. Como puede observarse, el primer turno presenta una similitud cercana a 1.0, lo cual es esperable dado que el estado dinámico inicial coincide con el embedding del primer turno. A medida que la conversación progresa, la similitud tiende a disminuir y presenta una mayor variabilidad, reflejando el efecto acumulativo del contexto conversacional sobre la representación dinámica. Debido a la superposición de un gran número de conversaciones, la visualización conjunta resulta altamente densa. Por esta razón, se analizó también una representación agregada basada en la similitud promedio por posición de turno. Esta síntesis permite observar de manera más clara la tendencia general de divergencia entre las representaciones estáticas y dinámicas a lo largo del diálogo.

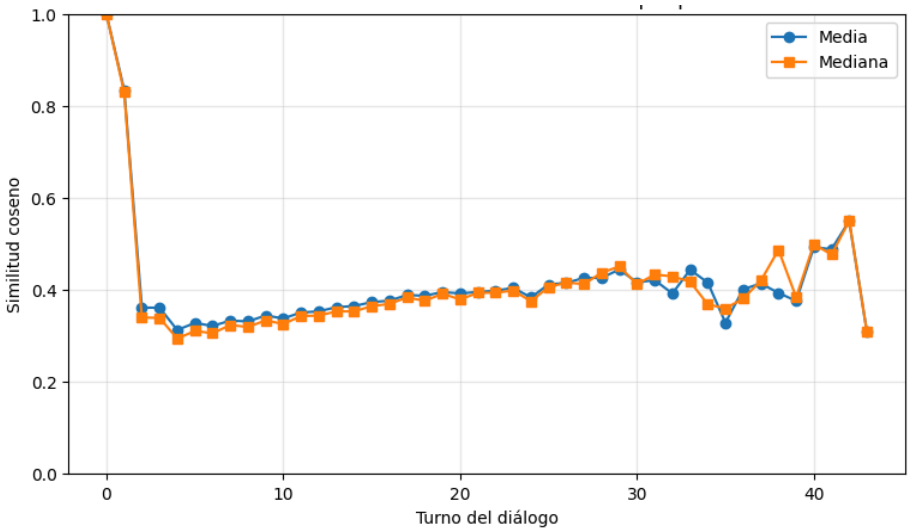

Figura 3: Tendencia central de la similitud estático-dinámico por posición de turno

Estos resultados sugieren que los estados latentes dinámicos capturan información semántica adicional que no está presente en los embeddings de turno individuales y por lo tanto podrían resultar útiles como consultas más informativas en sistemas de recuperación vectorial aplicados a agentes conversacionales orientados a tareas.

Finalmente, con el objetivo de explorar la estructura del espacio semántico generado por ambas representaciones, se aplicó reducción de dimensionalidad mediante UMAP sobre un subconjunto de 2000 vectores del corpus.

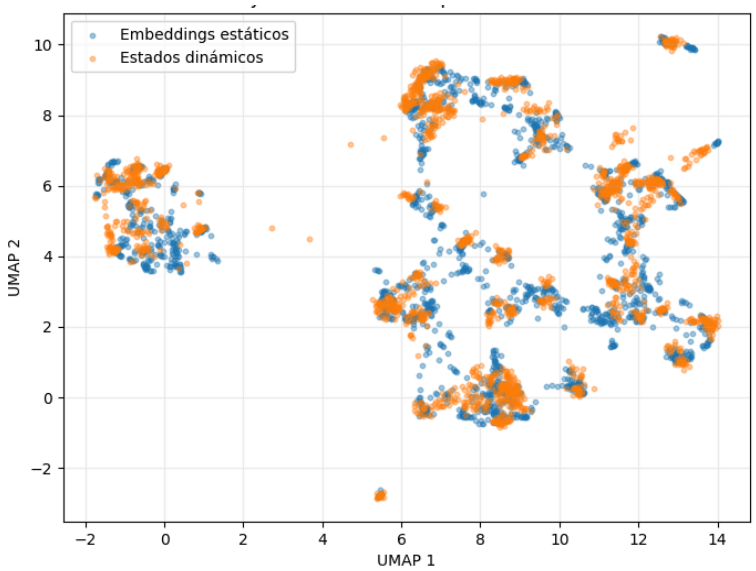

Figura 4: Proyección mediante UMAP de la comparación de representación estática y dinámica

La proyección bidimensional muestra que los embeddings de turno y los estados dinámicos ocupan regiones similares del espacio, preservando la estructura semántica global. No obstante, se observan desplazamientos locales de los estados dinámicos dentro de los

mismos clusters, lo que sugiere que la incorporación del contexto conversacional introduce variaciones en la representación sin alterar la organización general del espacio vectorial.

Conclusiones

En este trabajo se analizó el comportamiento de distintos métodos de búsqueda aproximada de vecinos aplicados a representaciones vectoriales generadas a partir de diálogos orientados a tareas. Los experimentos realizados sobre el corpus MultiWOZ 2.2 muestran que los índices ANN evaluados permiten recuperar vecinos con altos niveles de precisión manteniendo tiempos de consulta significativamente menores que la búsqueda exacta. En particular, el índice HNSW presenta el mejor compromiso entre eficiencia computacional y calidad de recuperación para los embeddings considerados.

A partir de estos resultados, se exploró la construcción de estados latentes dinámicos que integran progresivamente la información del historial conversacional. El análisis de la similitud entre embeddings de turno y estados dinámicos muestra que, a medida que el diálogo avanza, las representaciones dinámicas comienzan a divergir de los embeddings individuales, reflejando la incorporación de contexto acumulado en la representación semántica.

La visualización del espacio vectorial mediante reducción de dimensionalidad sugiere que estas representaciones dinámicas preservan la estructura semántica global del espacio, aunque introducen desplazamientos locales dentro de los mismos clusters. Este comportamiento es consistente con la definición recursiva del estado dinámico y sugiere que dichas representaciones capturan información contextual adicional sin perder la semántica del turno actual.

Estos resultados constituyen un primer paso hacia el uso de representaciones dinámicas del estado conversacional como consultas en sistemas de recuperación vectorial, lo que podría facilitar la identificación de estados de diálogo similares dentro de grandes colecciones de interacciones. En el contexto de futuras investigaciones, esta línea de trabajo resulta especialmente relevante para el desarrollo de agentes conversacionales más estructurados, capaces de reutilizar experiencias previas y combinar representaciones neuronales con mecanismos de recuperación y planificación.

En particular, esta perspectiva se vincula con el objetivo de investigar enfoques neuro-simbólicos para sistemas de diálogo orientados a tareas, donde representaciones semánticas aprendidas puedan integrarse con métodos de razonamiento y planificación para mejorar la toma de decisiones de los agentes conversacionales.

Referencias

- P. Budzianowski, T.-H. Wen, B.-H. Tseng, I. Casanueva, S. Ultes, O. Ramadan y M. Gašić, “MultiWOZ – A Large-Scale Multi-Domain Wizard-of-Oz Dataset for Task-Oriented Dialogue Modelling,” en Proceedings of the 2018 Conference on Empirical Methods in Natural Language Processing (EMNLP), Bruselas, Bélgica, 2018, pp. 5016–5026.
- S. Young, M. Gašić, B. Thomson y J. D. Williams, “POMDP-based statistical spoken dialog systems: A review”. Proceedings of the IEEE, vol. 101, no. 5, pp. 1160–1179, 2013.
- H. Chen, X. Liu, D. Yin y J. Tang, “A survey on dialogue systems: Recent advances and new frontiers”. ACM SIGKDD Explorations Newsletter, vol. 19, no. 2, pp. 25–35, 2017.
- J. Devlin, M.-W. Chang, K. Lee y K. Toutanova, “BERT: Pre-training of deep bidirectional transformers for language understanding” en Proceedings of NAACL-HLT 2019, Minneapolis, MN, USA, 2019, pp. 4171–4186.
- H. Jégou, M. Douze y C. Schmid, “Product quantization for nearest neighbor search,” IEEE Transactions on Pattern Analysis and Machine Intelligence, vol. 33, no. 1, pp. 117–128, Jan. 2011.
- J. Johnson, M. Douze y H. Jégou, “Billion-scale similarity search with GPUs” IEEE Transactions on Big Data, vol. 7, no. 3, pp. 535–547, 2021.
- Y. A. Malkov y D. A. Yashunin, “Efficient and robust approximate nearest neighbor search using Hierarchical Navigable Small World graphs” IEEE Transactions on Pattern Analysis and Machine Intelligence, vol. 42, no. 4, pp. 824–836, 2020.
- N. Reimers y I. Gurevych, “Sentence-BERT: Sentence embeddings using Siamese BERT-networks” en Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing (EMNLP), Hong Kong, 2019, pp. 3982–3992.